Pipeline de Dados com IoT e Docker

Relatório técnico | Disruptive Architectures: IoT, Big Data e IA

Autor: [preencher nome do aluno] Instituição: [preencher] Data: outubro de 2026

1. Contextualização e objetivo

O projeto implementa um pipeline para análise de leituras históricas de temperatura de dispositivos IoT. Os dados são obtidos do conjunto “Temperature Readings: IoT Devices”, disponibilizado no Kaggle, tratados em Python, armazenados em PostgreSQL executado por Docker e apresentados em um dashboard interativo com Streamlit e Plotly. O objetivo é demonstrar as etapas de ingestão, persistência, agregação SQL e visualização de dados.

2. Arquitetura e tecnologias

Camada	Tecnologia	Responsabilidade
Fonte	CSV / Kaggle	Leituras de temperatura e metadados
Ingestão	Python / Pandas	Leitura em lotes, normalização de data e temperatura
Persistência	PostgreSQL 16 / Docker Compose	Tabela temperature_readings e volume persistente
Análise	SQL / 3 views	Médias, contagem por hora, extremos diários
Apresentação	Streamlit / Plotly	Indicadores e gráficos interativos

Fluxo: CSV → Python/Pandas → PostgreSQL em Docker → Views SQL → Streamlit/Plotly. O sistema trabalha com dados históricos; não há transmissão de sensores em tempo real.

3. Configuração e execução

O projeto inclui docker-compose.yml, requirements.txt, run.ps1, código Python em src/, consultas em sql/ e instruções no README. O script run.ps1 prepara o ambiente Python, inicializa o PostgreSQL, importa o CSV, cria as views e inicia o dashboard. O Docker foi observado em execução com imagem postgres:16, contêiner pipeline-iot-postgres-1, status Healthy e publicação local 127.0.0.1:5433 → 5432/tcp.

4. Caracterização do dataset

Indicador	Resultado
Registros	97.606
Datas com registros	86
Período	28/07/2018 a 08/12/2018
Leituras internas (In)	20.345
Leituras externas (Out)	77.261
Temperatura média interna	30,45 °C
Temperatura média externa	36,27 °C
Valores nulos / datas inválidas	0 / 0

A coluna room_id/id apresenta apenas “Room Admin”. As categorias In e Out são pontos lógicos de medição, não prova de dois sensores físicos independentes. Os indicadores foram calculados a partir do CSV; os números exibidos no dashboard são consistentes com esse levantamento.

5. Views SQL implementadas

avg_temp_por_dispositivo: agrupa as leituras pelo campo lógico device_id e calcula AVG(temperature) e COUNT(*). No dataset utilizado, permite comparar Room Admin | In e Room Admin | Out.

leituras_por_hora: extrai a hora do campo recorded_at e agrupa registros por hora (0 a 23). O resultado mostra a distribuição da frequência das medições ao longo do dia, não uma série de temperatura média.

temp_max_min_por_dia: agrupa as leituras pela data e calcula MAX(temperature), MIN(temperature) e AVG(temperature). Permite identificar extremos e oscilações ao longo do período registrado.

6. Evidências da execução

A captura abaixo mostra o dashboard Streamlit aberto em localhost:8501, exibindo 97.606 leituras, 86 dias e dois pontos lógicos de medição, além do gráfico de temperatura média e do início da visualização por hora.

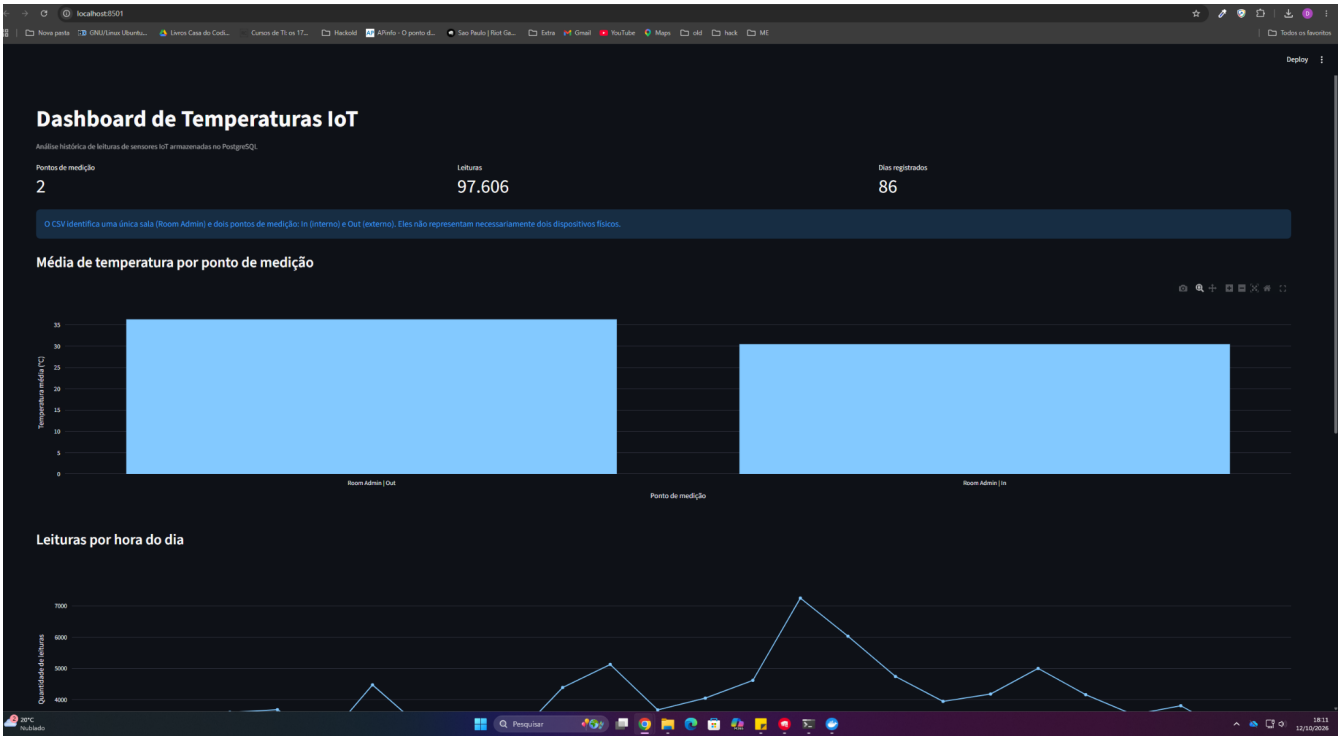


Figura 1 — Dashboard Streamlit em execução, com indicadores e gráfico de temperatura média. Fonte: captura da execução local fornecida pelo aluno.

6. Evidências da execução (continuação)

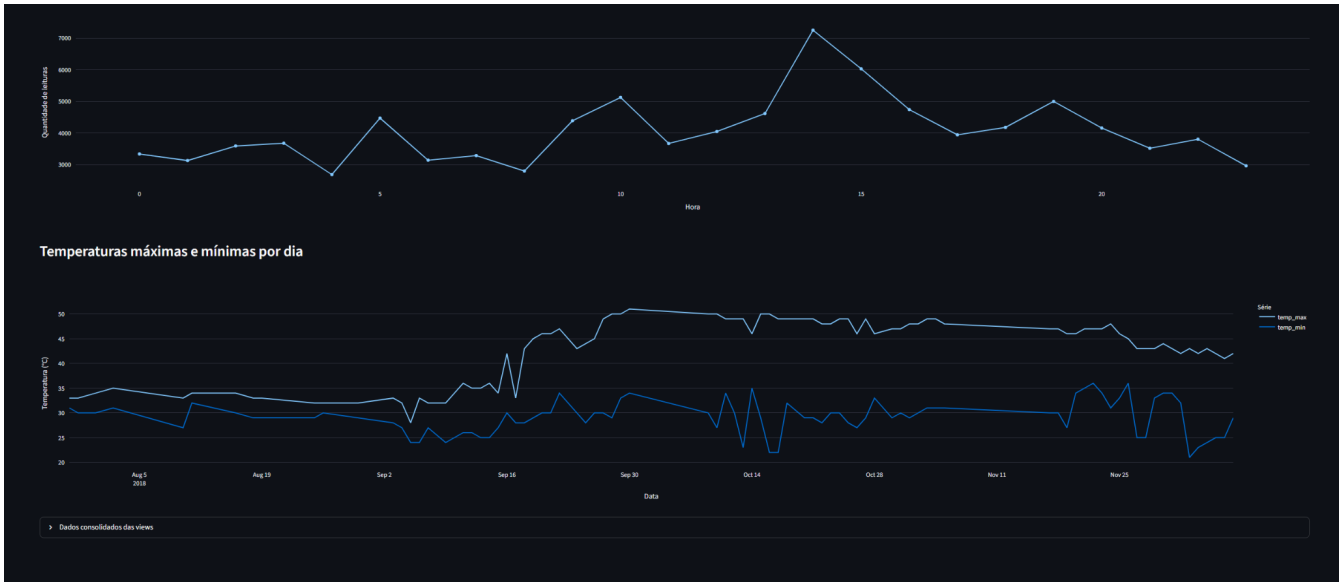


Figura 2 — Gráficos de leituras por hora e temperaturas máximas e mínimas por dia. Fonte: captura da execução local fornecida pelo aluno.

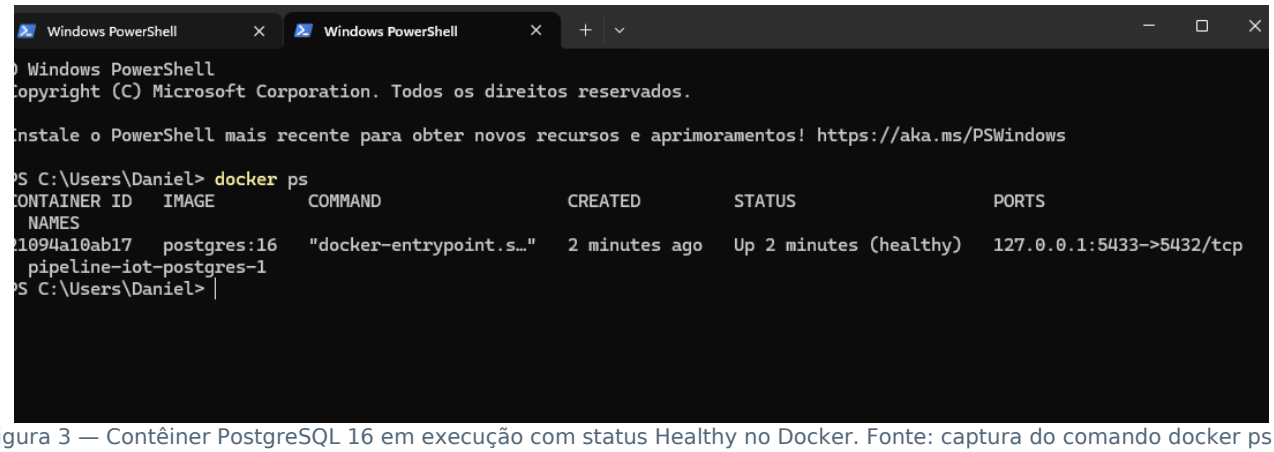


Figura 3 — Contêiner PostgreSQL 16 em execução com status Healthy no Docker. Fonte: captura do comando docker ps fornecida pelo aluno.

7. Resultados e insights

Diferença entre ambientes: a média externa (36,27 °C) supera a média interna (30,45 °C) em aproximadamente 5,82 °C. A comparação sugere diferenças térmicas entre os pontos monitorados, sem permitir inferir causalidade ou condições de calibração.

Frequência de coleta: o gráfico por hora apresenta concentração desigual de leituras, com pico visual próximo de 14h. Esse resultado pode orientar uma investigação sobre cadência de coleta, disponibilidade de sensores e horários de maior atividade; não implica maior temperatura nesse horário.

Variação diária: a série de máximas e mínimas mostra mudanças ao longo do período e episódios de maior amplitude térmica. Em aplicação real, tais dados poderiam alimentar alertas de temperatura, análises de conforto ambiental e manutenção preventiva, mediante definição de limites adequados e validação dos sensores.

8. Validação, limitações e recomendações

As capturas evidenciam a renderização dos três gráficos, a leitura de indicadores e o contêiner PostgreSQL saudável. Não foi anexada a saída de uma consulta SQL manual ou de um teste automatizado de integração ponta a ponta. A existência dos gráficos demonstra funcionamento observável da aplicação, mas não substitui testes adicionais de integridade e reprodutibilidade.

Para reproduzir o projeto: instalar Python e Docker Desktop, obter o CSV do Kaggle, executar run.ps1 e abrir a URL local do Streamlit. Recomenda-se confirmar SELECT COUNT(*) na tabela temperature_readings, validar as três views e registrar o procedimento no vídeo de apresentação.

9. Conclusão

O projeto demonstra um fluxo funcional de análise de dados históricos IoT: ingestão por Python, armazenamento em PostgreSQL containerizado, consultas analíticas SQL e visualização com Streamlit. A execução observada apresenta indicadores coerentes com o dataset e os três gráficos previstos no enunciado. A solução é reproduzível e pode ser ampliada para coleta em tempo real em trabalhos futuros.

10. Referências e artefatos

Dataset: Temperature Readings: IoT Devices — Kaggle. Código-fonte: [inserir URL do repositório público GitHub antes da entrega]. Vídeo pitch: [inserir URL após publicação].